

Tổng Quan về Bài Toán Text-to-Speech (TTS)

Trần Minh Anh

Ngày 1 tháng 12 năm 2025

1 Giới thiệu

Text-to-Speech (TTS) là công nghệ biến văn bản(text) thành giọng nói(speech), giúp máy tính “đọc to” nội dung văn bản một cách tự nhiên.

Quá trình TTS nói chung thường gồm các bước chính: đầu vào văn bản → xử lý ngôn ngữ (phân tích văn bản, phân tách âm vị, ngữ điệu, ...) → tổng hợp giọng nói (speech synthesis) → xuất âm thanh [1, 2].

TTS có ứng dụng rộng rãi: trợ lý ảo, đọc sách nói, hỗ trợ người khiếm thị, chuyển nội dung web thành âm thanh, tổng đài tự động, audiobook, lồng tiếng, v.v. [1].

Qua lịch sử phát triển, TTS đã trải qua nhiều giai đoạn, từ phương pháp đơn giản, dựa trên ghép nối âm thanh, đến các phương pháp hiện đại dùng học máy, học sâu, tạo giọng nói tự nhiên và linh hoạt hơn.

2 Các cấp độ phát triển của TTS

2.1 Level 1: Rule-based / Concatenative TTS (ghép âm / dựa trên luật âm vị)

Mô tả: Phương pháp truyền thống, sử dụng cơ sở âm thanh đã ghi sẵn (sample recordings) chia thành các đơn vị âm nhỏ (âm vị, âm tiết, diphone, phoneme...). Khi cần đọc văn bản, hệ thống phân tích văn bản - ánh xạ sang các âm vị / âm tiết tương ứng rồi "ghép" các đoạn âm thanh đã ghi sẵn lại để tạo câu nói. [3, 4].

Ưu điểm:

- Đơn giản, không yêu cầu training phức tạp hay dữ liệu lớn.
- Chạy nhanh, ít phụ thuộc vào dữ liệu, phù hợp với nhiều ngôn ngữ nếu có cơ sở âm thanh phù hợp.

- Có thể đảm bảo phát âm rõ và ổn định (vì dùng giọng thật đã ghi), khi hợp âm tốt.

Nhược điểm:

- Giọng nói tổng hợp thường thiếu tự nhiên, “robotic”, thiếu ngữ điệu, cảm xúc, linh hoạt — đặc biệt khó với những câu dài, phức tạp.
- Khó mở rộng: để hỗ trợ ngữ điệu mới, từ mới, ngôn ngữ mới — cần ghi lại rất nhiều âm thanh.
- Giới hạn trong việc thay đổi cao độ, tốc độ nói, cảm xúc, phong cách nói.

Phù hợp với:

- Ứng dụng đơn giản, không yêu cầu giọng tự nhiên cao: hệ thống nhắc máy, thiết bị đọc văn bản cơ bản, hỗ trợ người khiếm thị, đọc thông báo, SMS-to-speech, các ngôn ngữ ít tài nguyên,...
- Khi dữ liệu âm thanh hạn chế, hoặc muốn tiêu tốn ít tài nguyên tính toán.

2.2 Level 2: Deep Learning / Neural TTS

Mô tả:

- Với sự phát triển của học máy, đặc biệt mạng nơ-ron sâu (deep neural networks), người ta chuyển sang dùng mô hình học để tổng hợp giọng nói từ văn bản. [6]
- Quy trình thường: văn bản → phân tích và xử lý ngôn ngữ → mô hình chuyển thành đặc trưng âm học (thường mel-spectrogram hoặc các dạng spectrogram) → vocoder (mạng sinh âm thanh) tạo sóng âm thanh thực. Ví dụ: một mô hình phổ biến là Tacotron 2 (text → mel-spectrogram) + WaveNet (mel → waveform).[5]
- Nhờ đó, giọng nói tổng hợp gần giống giọng người thật hơn, có thể điều chỉnh ngữ điệu, nhịp điệu, tốc độ, cao độ, cảm xúc... tốt hơn.

Ưu điểm:

- Giọng nói “tự nhiên”, mượt mà, giàu biểu cảm hơn — gần với giọng con người thực.
- Linh hoạt: có thể điều chỉnh cao độ, tốc độ, ngữ điệu, phong cách nói. Có thể hỗ trợ đa ngôn ngữ, đa giọng (nếu dữ liệu đủ).

- Có khả năng mở rộng tốt hơn, dễ huấn luyện lại, fine-tune, cải tiến — phù hợp với ứng dụng hiện đại như trợ lý ảo, đọc sách nói, hệ thống đa ngôn ngữ, voice-over, ...

Nhược điểm:

- Đòi hỏi dữ liệu ghi âm lớn (giọng người thật, chất lượng cao). Việc thu thập, xử lý dữ liệu tốn công sức, đặc biệt cho từng ngôn ngữ/giọng.
- Cần tài nguyên tính toán đáng kể — training mô hình, inference, vocoder... có thể “nặng”.
- Với ngôn ngữ ít dữ liệu hoặc giọng hiếm, dễ gặp khó khăn về chất lượng, tự nhiên, rõ ràng.

Phù hợp với:

- Ứng dụng cần giọng nói tự nhiên, chất lượng cao: trợ lý ảo, đọc sách nói, nội dung media, voice-over, đa ngôn ngữ, hệ thống speech AI chuyên nghiệp.
- Các ngôn ngữ lớn, có sẵn dữ liệu ghi âm, hoặc các tổ chức / dịch vụ sẵn sàng đầu tư dữ liệu compute.

2.3 Level 3: Few-Shot / Zero-Shot (Voice Cloning / Speaker Adaption)

Mô tả:

- Đây là hướng hiện đại nhất: cho phép tạo giọng nói với đặc trưng của một người cụ thể — chỉ cần tầm vài giây đến vài chục giây âm thanh mẫu (reference) — rồi tổng hợp giọng nói theo văn bản đầu vào với giọng giống người đó. [7, 8, 9].
- Trong pipeline hiện đại: có mô-đun “speaker encoder” để trích đặc trưng giọng từ âm mẫu; tách riêng phần “nội dung” (text → phoneme/linguistic content) và “giọng người” (speaker embedding); rồi mô hình sinh giọng nói kết hợp cả 2 để tạo speech cá nhân hóa.
- Có các kỹ thuật few-shot adaptation (fine-tune mô hình gốc với dữ liệu nhỏ), hoặc zero-shot (không cần fine-tune, dùng trực tiếp speaker embedding) tùy phương pháp.

Ưu điểm:

- Có thể cá nhân hóa giọng nói: voice cloning làm được giọng giống người thật — rất hữu ích cho trợ lý ảo “giọng riêng”, lồng tiếng, audiobook, phục hồi giọng nói, ứng dụng người khuyết tật, nhân bản giọng người nổi tiếng.
- Tiết kiệm dữ liệu so với đào tạo từ đầu (chỉ cần vài giây đến vài phút audio mẫu thay vì hàng giờ).
- Tiềm năng hỗ trợ đa ngôn ngữ, đa giọng, đa người — nếu pipeline tốt: có thể dùng một mô hình chung (multi-speaker), sau đó “điều chỉnh” riêng cho từng người.

Nhược điểm:

- Mặc dù tiến bộ nhiều, nhưng với ít dữ liệu thì vẫn có thể có “degradation” về chất lượng: giọng tổng hợp có thể kém tự nhiên hơn, prosody/intonation không ổn định, đặc biệt nếu speech dài.
- Khó đảm bảo ổn định cho nhiều câu dài — voice identity và độ tự nhiên có thể giảm dần theo thời lượng.
- Cần thiết kế pipeline chuyên biệt — speaker encoder, disentanglement giữa nội dung và giọng, vocoder hỗ trợ đa-speaker, xử lý ngôn ngữ, có thể thêm post-processing / voice conversion để cải thiện — làm tăng độ phức tạp hệ thống.
- Có các vấn đề liên quan đến đạo đức, riêng tư, misuse (deepfake giọng nói) nếu áp dụng không đúng.

Phù hợp với:

- Ứng dụng yêu cầu cá nhân hóa giọng nói: trợ lý ảo cá nhân, audiobook với “giọng người dùng”, voice-over, lồng tiếng, phục hồi giọng nói, ứng dụng người khuyết tật.
- Khi dữ liệu audio nhiều không khả thi/không sẵn, hoặc muốn tạo giọng riêng nhanh, dễ dàng.
- Khi cần voice cloning đa người, đa giọng, đa ngôn ngữ, mà vẫn tiết kiệm dữ liệu.

3 Một số phương pháp và pipeline hiện đại: cách kết hợp để tối ưu / khắc phục nhược điểm

Nhiều nghiên cứu gần đây đã phát triển các pipeline tinh vi để tận dụng ưu điểm của deep TTS + voice cloning, đồng thời giảm nhược điểm (dữ liệu, chất lượng, tính đa dạng, hiệu năng). Một số ví dụ:

- VALL-E — một “neural codec language model” (2025) coi TTS như một bài toán mô hình ngôn ngữ có điều kiện: sử dụng các code rời rạc (discrete codes) từ neural audio codec, chứ không mô hình continuous waveform, giúp tổng hợp speech chất lượng cao, màu giọng tự nhiên, thậm chí preserve cả cảm xúc và môi trường âm thanh từ prompt chỉ khoảng 3 giây [9]
- Một nghiên cứu (2022) Voice Filter dùng voice-conversion làm module hậu xử lý (post-processing) thêm vào TTS hiện có — cho phép “few-shot TTS” với chỉ 1 phút speech mẫu, và kết quả competitive so với TTS được huấn luyện từ dữ liệu lớn. [10]
- Hướng “few-shot voice cloning + disentanglement” như trong Meta-Voice: dùng meta-learning (MAML) để fine-tune một TTS base (multi-speaker, multi-prosody) — cho phép adaption nhanh với chỉ 5 mẫu (khoảng 12s speech) từ speaker mới; sử dụng adversarial domain và orthogonal constraint để tách “speaker identity” và “prosody/content” hiệu quả [11]
- Kế thừa hơn: nhiều hệ thống now hỗ trợ multilingual TTS, cross-lingual voice cloning, low-resource languages — nghĩa là có khả năng dùng dữ liệu hạn chế mà vẫn tổng hợp được speech trong nhiều ngôn ngữ khác nhau. [12]

Nhờ các pipeline này, các hệ thống TTS hiện đại có thể: giữ giọng cá nhân, đa ngôn ngữ, ít dữ liệu, nhưng vẫn giữ tính tự nhiên cao — phù hợp cho ứng dụng thực tế rộng (virtual assistant, audiobook, voice-over, voice cloning, accessibility, ...).

4 So sánh các cấp độ TTS

Level	Khi nào dùng	Ưu điểm	Nhược điểm
Rule-based / Concatenative	Nhu cầu đơn giản, giọng “cơ bản”, ít tài nguyên, ngôn ngữ ít phổ biến, hay hệ thống nhắc / đọc đơn giản	Nhanh, nhẹ, dễ thực hiện, ít phụ thuộc dữ liệu	Giọng thiếu tự nhiên, cứng nhắc, thiếu ngữ điệu, khó mở rộng
Deep-Learning / Neural TTS	Khi cần giọng tự nhiên, chất lượng cao; ngôn ngữ phổ biến; có dữ liệu và compute	Giọng tự nhiên, mượt, linh hoạt phong cách, dễ điều chỉnh, dễ mở rộng	Cần dữ liệu và compute lớn; khó cho ngôn ngữ/tài nguyên ít
Few-Shot / Zero-Shot / Voice Cloning	Cần giọng cá nhân hóa, voice-over, audiobook, người khuyết tật, đa giọng, đa ngôn ngữ, tiết kiệm dữ liệu	Cá nhân hoá giọng, ít dữ liệu, đa người/đa ngôn ngữ, linh hoạt	Đòi hỏi pipeline phức tạp; với data ít vẫn có thể giảm chất lượng; có vấn đề đạo đức/riêng tư

Bảng 1: So sánh các hướng tiếp cận TTS theo cấp độ

5 Kết luận

Bài toán Text-to-Speech (TTS) đã trải qua một hành trình phát triển dài, từ các hệ thống dựa trên quy tắc đơn giản (rule-based) đến các mô hình học sâu hiện đại và những hướng tiếp cận cá nhân hoá giọng nói. Mỗi giai đoạn mang lại bước tiến đáng kể về độ tự nhiên, khả năng biểu cảm, và mức độ linh hoạt của giọng tổng hợp.

Cụ thể, các phương pháp dựa luật có ưu điểm về tốc độ và khả năng triển khai trên nhiều ngôn ngữ nhưng giọng còn thiếu tự nhiên. Sự xuất hiện của học sâu đã mở ra khả năng tạo ra giọng nói mượt mà, cảm xúc và chân thực hơn, tuy nhiên vẫn đòi hỏi lượng dữ liệu và tài nguyên tính toán lớn. Cuối cùng, hướng tiếp cận cá nhân hoá như few-shot và zero-shot TTS — đã giúp mô hình có thể tái tạo giọng nói của từng cá nhân chỉ với vài giây âm thanh, mở ra tiềm năng ứng dụng rộng rãi trong voice cloning, trợ lý ảo, audiobook hay phục hồi giọng nói cho người khiếm khuyết.

Xu hướng hiện nay là xây dựng các hybrid pipeline, kết hợp sức mạnh của

Deep Learning với các kỹ thuật thích ứng giọng nói (speaker adaptation), nhằm tận dụng ưu điểm của từng phương pháp và giảm thiểu nhược điểm như phụ thuộc dữ liệu hoặc chi phí tính toán. Nhờ đó, TTS không chỉ trở nên tự nhiên hơn, mà còn tiến gần hơn đến khả năng “cá nhân hoá giọng nói” cho mọi người dùng.

Tổng thể, sự phát triển của TTS minh chứng cho vai trò quan trọng của trí tuệ nhân tạo trong giao tiếp người-máy. Với tốc độ tiến bộ của các mô hình sinh (generative models) và học chuyển giao (transfer learning), TTS hứa hẹn sẽ tiếp tục đạt được chất lượng cao hơn, đa ngôn ngữ hơn, và thân thiện hơn với từng cá nhân trong tương lai gần.

Tài liệu

- [1] FPT.AI, “Text-to-Speech là gì?” <https://fpt.ai/vi/bai-viet/text-to-speech-la-gi>
- [2] Viettel AI, “Nguyên lý hoạt động công nghệ Text-to-Speech” <https://viettelai.vn/tin-tuc/nguyen-ly-hoat-dong-cong-nghe-text-to-speech>
- [3] Newstory, “Lịch sử phát triển giọng đọc AI” <https://newstory.vn/blogs/lich-su-phat-trien-giong-doc-ai>
- [4] Coin98, “Text-to-Speech (TTS) là gì?” <https://coin98.net/text-to-speech-tts>
- [5] Viblo, “Tìm hiểu một số mô hình Text-to-Speech” <https://viblo.asia/p/tim-hieu-1-so-mo-hinh-text-to-speech-p1-vyDZORjQKwj>
- [6] Github “A Survey on Neural Speech Synthesis” <https://github.com/tts-tutorial/survey>
- [7] ArXiv, “VALL-E: Neural codec language model for TTS” <https://arxiv.org/html/2505.00579v1>
- [8] LyricWinter, “Voice Cloning Evolution” <https://lyricwinter.com/blog/voice-cloning-evolution>
- [9] ResearchGate, “Human Voice Synthesis and Cloning Using Generative AI Models” <https://www.researchgate.net/publication/397839594>
- [10] ArXiv “Voice Filter: Few-shot text-to-speech speaker adaptation using voice conversion as a post-processing module” <https://arxiv.org/abs/2202.08164>

- [11] ArXiv “Meta-Voice: Fast few-shot style transfer for expressive voice cloning using meta learning” <https://arxiv.org/abs/2111.07218>
- [12] JSIAR “Deep Voice and Beyond: Innovations in Real-Time Neural Text-to-Speech Synthesis” <https://jsiar.com/2025-July/JSIAR-J-25-07101.pdf>